### Automated extractions of some phenotypic data tables from the UKBiobank

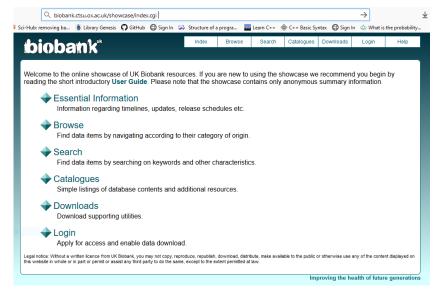
Futurologist

February 24, 2020

#### Introduction

- ▶ **UKBiobank:** Genotypic data, Phenotypic data (such as health condition history, imaging, blood tests, etc) and Environmental factors of nearly 500000 people;
- ► Possibly to reduce the file-sizes, the raw phenotypic data in the UKB is in a format not suitable for statistical analysis
- ▶ It needs to be converted to more useful data tables, e.g. tables with binary entries for binary categorical variables.
- ▶ I have tried to write some R code that converts some subtables of the raw UKB data-files to formats more suitable for statistical analysis.

#### UKBiobank Documentation Website: Homepage



#### UKBiobank Structure: Top Level

At a **UKB** Assessment Center, the patients filled out a **touchscreen** questionnaire and then some results were discussed with a health-care professional during a **verbal interview**.



### UK Biobank Assessment Center $\rightarrow$ Verbal Interview $\rightarrow$ Medical Conditions

#### Description

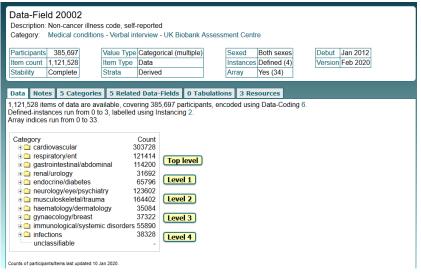
This category contains data obtained through a verbal interview by a trained nurse on past and current medical conditions, including type of cancer and other illnesses, the number of medical conditions, and date of diagnosis.

The interviewer was made aware via a pop-up box on their computer screen if the participant had answered in the touchscreen that they had a history of one or more of the following illnesses: heart attack, angina, stroke, high blood pressure, blood clot in leg, blood clot in lug, emphysema/chronic bronchitis, asthma or diabetes, and was prompted to confirm these with the participant (these will already be selected in the illness screen if they had been selected during the touchscreen questionnaire). If during the interview it appeared these had been incorrectly selected, the interviewer could amend the responses. If the participant stated in the touchscreen they had no major illnesses or disability or were not sure, this question was asked again and confirmed by the interviewer. Medical conditions that could not be assigned a code at the time of the interview were entered as free text, and subsequently coded wherever possible

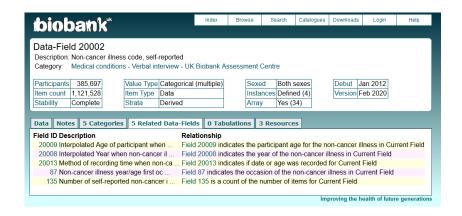
13 Dat	-Fields 1 Parent Category 3 Resources
Field II	Description
20001	Cancer code, self-reported
84	Cancer year/age first occurred
20007	Interpolated Age of participant when cancer first diagnosed
20009	Interpolated Age of participant when non-cancer illness first diagnosed
20006	Interpolated Year when cancer first diagnosed
20008	Interpolated Year when non-cancer illness first diagnosed
20012	Method of recording time when cancer first diagnosed
20013	Method of recording time when non-cancer illness first diagnosed
20002	Non-cancer illness code, self-reported
87	Non-cancer illness year/age first occurred
134	Number of self-reported cancers
135	Number of self-reported non-cancer illnesses
3140	Pregnant

#### Data-Field 20002: Self-Reported Medical Conditions

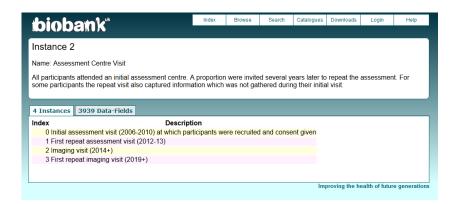
Check: Data, Related Data-Fields, instancing 2, Data-Coding 6, Notes



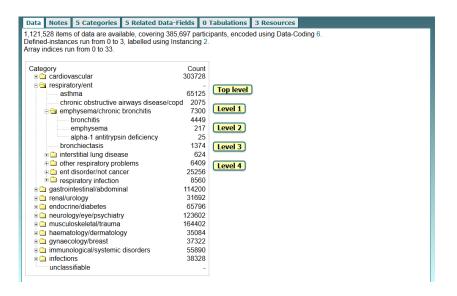
#### Data-Field 20002: Related Data-Fields



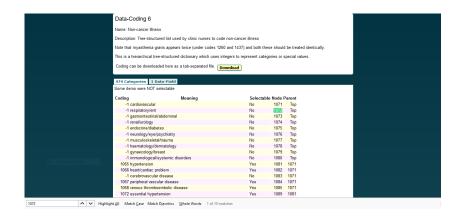
#### Data-Field 20002: Instancing (number of visits)



#### Data-Field 20002



#### Data-Field 20002: Data-Codes 6



#### Data-Field 20002: Data-Codes 6

Data-Field Code: header of a UKB data table (e.g. 20002) Data-Code: entry in a UKB data table (e.g. 1111 for Asthma)

1074 angina	Yes	1091	1082	
1075 heart attack/myocardial infarction	Yes	1092	1082	
1076 heart failure/pulmonary odema	Yes	1093	1082	
1077 heart arrhythmia	Yes	1094	1082	
1078 heart valve problem/heart murmur	Yes	1095	1082	
1079 cardiomyopathy	Yes	1096	1082	
1080 pericardial problem	Yes	1097	1082	
1081 stroke	Yes	1098	1083	
1082 transient ischaemic attack (tia)	Yes	1099	1083	
1083 subdural haemorrhage/haematoma	Yes	1100	1083	
1086 subarachnoid haemorrhage	Yes	1103	1098	
1087 leg claudication/ intermittent claudication	Yes	1104	1084	
1088 arterial embolism	Yes	1105	1084	
1093 pulmonary embolism +/- dvt	Yes	1111	1085	
1094 deep venous thrombosis (dvt)	Yes	1112	1085	
1111 asthma	Yes	1130	1072	
1112 chronic obstructive airways disease/copd	Yes	1131	1072	
1113 emphysema/chronic bronchitis	Yes	1132	1072	
1114 bronchiectasis	Yes	1133	1072	
1115 interstitial lung disease	Yes	1134	1072	
1117 other respiratory problems	Yes	1136	1072	
1120 asbestosis	Yes	1139	1134	
1121 pulmonary fibrosis	Yes	1140	1134	
1122 fibrosing alveolitis/unspecified alveolitis	Yes	1141	1134	
1123 sleep apnoea	Yes	1142	1136	
1124 respiratory failure	Yes	1143	1136	
1125 pleurisy	Yes	1144	1136	
1126 spontaneous pneumothorax/recurrent pneumothorax	Yes	1145	1560	
1134 oesophageal disorder	Yes	1153	1073	
1135 stomach disorder	Yes		1073	
-1 bowel problem	No	1155	1073	

#### A Raw UKB Subtable: Example

Data-Field Code: header of a UKB data table (e.g. 20002)
Data-Code: entry in a UKB data table (e.g. 1111 for Asthma)
Here: Related Data-Fields 135 (number of self-reported conditions)
20002 (self-reported conditions) and 20009 (age of onset)

		Filter Cols:	≪ < 1 - 50	> >									(Q		
*	f.eid :	f.135.0.0 °	f.135.1.0	f.135.2.0	f.20002.0.0 °	f.20002.0.1 °	f.20002.0.2 <sup>0</sup>	f.20002.0.3	f.20002.0.4 °	f.20002.0.5	f.20002.0.6 °	f.20002.0.7 <sup>‡</sup>	f.20002.0.8	f.2000	)2.0
1	1000016	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	٦
2	1000021	0	NA	NA	NA	NA	NA.	NA	NA	NA	NA	NA	NA	NA	
3	1000033	1	5	0	1537	NA	NA	NA	NA	NA	NA	NA	NA	NA	
4	1000049	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
5	1000057	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
6	1000065	1	NA	NA	1462	NA	NA	NA	NA	NA	NA	NA	NA	NA	
7	1000070	3	NA	NA	1065	1473	1465	NA	NA	NA	NA	NA	NA	NA	
8	1000082	2	NA	NA	1278	1309	NA	NA	NA	NA	NA	NA	NA	NA	
9	1000098	4	NA	NA	1465	1387	1529	1666	NA	NA	NA	NA	NA	NA	
LO	1000103	1	NA	NA	1075	NA	NA	NA	NA	NA	NA	NA	NA	NA	
11	1000111	1	NA	NA	1426	NA	NA	NA	NA.	NA	NA	NA	NA	NA	
12	1000126	4	NA	NA	1065	1111	1138	1286	NA	NA	NA	NA	NA	NA	
13	1000134	0	NA.	NA	NA	NA	NA.	NA	NA	NA	NA	NA	NA	NA	
14	1000142	2	NA	NA	1412	1311	NA.	NA	NA	NA	NA	NA	NA	NA	
15	1000155	6	NA	NA	1075	1074	1065	1473	1465	1078	NA	NA	NA	NA	
16	1000167	0	NA	NA	NA	NA	NA.	NA	NA	NA	NA	NA	NA	NA	
17	1000178	1	NA	NA	1111	NA	NA	NA	NA	NA	NA	NA	NA	NA	
18	1000189	1	NA	NA	1465	NA	NA	NA	NA	NA	NA	NA	NA	NA	
19	1000190	1	NA	NA	1135	NA	NA	NA	NA	NA	NA	NA	NA	NA	
20	1000205	1	NA	NA	1473	NA	NA	NA	NA	NA	NA	NA	NA	NA	

#### A Raw UKB Subtable: Example

We extract from a \*.r.tab file, columns (fields) have headers f.datafieldnum.visit.arrayindx i.e. 'f.20002.1.3'

f.20002.0.28	f.20002.1.0	f.20002.1.1	f.20002.1.2	f.20002.1.3	f.20002.1.4 °	f.20002.1.5	f.20002.1.6 °	f.20002.1.7	f.20002.1.8	f.20002.1.9	f.20002.1.10	f.20002.1
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	1387	1534	1631	1568	1571	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
LA .	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
IA .	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA.	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA Rects	NA NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA

### A Raw UKB Subtable: Example

	Filter Cols f,20002,2,26		f.20002.2.28	f,20009,0,0	f,20009.0.1	f,20009,0,2	f.20009.0.3	f,20009.0.4	f,20009.0.5	f.20009.0.6	f.20009.0.7	f,20009.0.8	
25													
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	55.45630	NA								
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	23.00380	NA								
	NA	NA	NA	62.50000	62.500000	57.4247	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	66.30120	61.323500	NA							
	NA	NA	NA	57.90390	24.500000	66.9034	55.50000	NA	NA	NA	NA	NA	
	NA	NA	NA	50.50000	NA								
	NA	NA	NA	38.48120	NA								
	NA	NA	NA	45.50000	53.500000	51.6724	54.67320	NA	NA	NA	NA	NA	
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	10.50000	28.695900	NA							
	NA	NA	NA	37.50000	37.500000	37.5000	37.50000	66.5000	40.5000	NA	NA	NA	
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	NA	NA	NA	-1.00000	NA								
	NA	NA	NA	37.02460	NA								
	NA	NA	NA	61.07160	NA								
	NA	NA	NA	34.23480	NA								

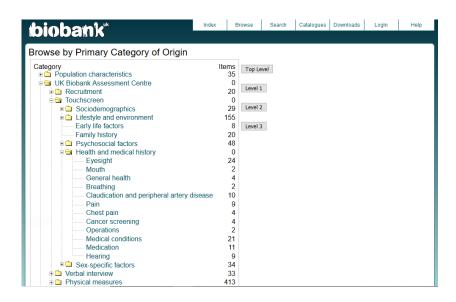
# Converted Table for conditions Asthma, Hay-Fever, Eczema including Age of Onset:

												(Q		
*	ID ÷	Asthma_v0	Asthma_v1	Asthma_v2	Hayf_Rhin_v0	Hayf_Rhin_v1 **	Hayf_Rhin_v2	Eczema_v0 ÷	Eczema_v1 :	Eczema_v2 <sup>0</sup>	age_Asthma_v0 **	age_Asthma_v1	age_	Ast
1	1000016	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
2	1000021	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
3	1000033	0	0	0	0	1	0	0	0	0	NA	NA	NA	
4	1000049	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
5	1000057	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
6	1000065	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
7	1000070	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
8	1000082	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
9	1000098	0	NA	NA	1	NA	NA	0	NA	NA	NA	NA	NA	
10	1000103	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
11	1000111	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
12	1000126	1	NA	NA	0	NA	NA	0	NA	NA	53.5000	NA	NA	
13	1000134	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
4	1000142	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
15	1000155	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
16	1000167	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
7	1000178	1	NA	NA	0	NA	NA	0	NA	NA	-1.0000	NA	NA	
8	1000189	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
9	1000190	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
20	1000205	0	NA	NA	0	NA		0	NA	NA	NA	NA	NA	+

# Converted Table for conditions Asthma, Hay-Fever, Eczema including Age of Onset:

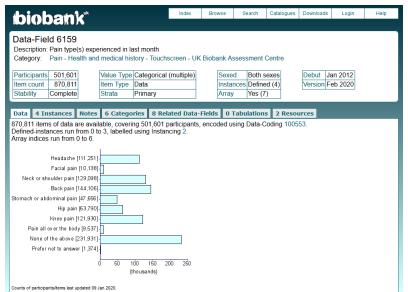
) 20   7 M	ter								Q,
Eczema_v2	age_Asthma_v0	age_Asthma_v1	age_Asthma_v2	age_Hayf_Rhin_v0	age_Hayf_Rhin_v1 **	age_Hayf_Rhin_v2	age_Eczema_v0 **	age_Eczema_v1 **	age_Eczema_v2
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
0	NA	NA	NA	NA	44.5785	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	24.50000	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	53.5000	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	-1.0000	NA	NA	NA	NA	NA	NA	NA	NA
NA Rec	NA NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA

#### UK Biobank Assessment Center $\rightarrow$ Touchscreen $\rightarrow$ Pain

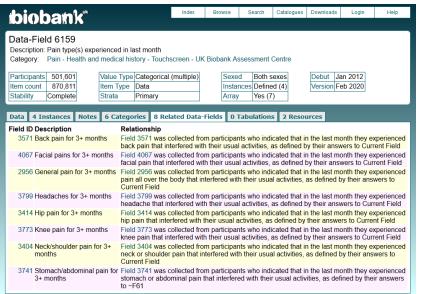


#### Data-Field 6159: Data

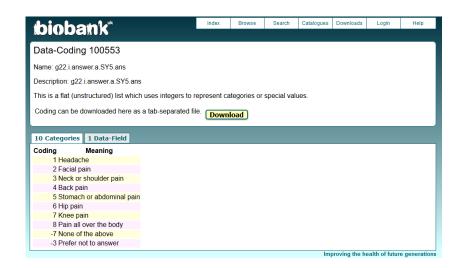
**Check:** Data, Related Data-Fields, instancing 2, Data-Coding 100553, Notes



#### Data-Field 6159: Related Fields



#### Data-Field 6159: Data-Coding



#### A Raw UKB Subtable 6159 and Related Fields

				× P Set_of_fu								rp_bin × fr		120002 >>	
	le!													(Q,	
	f.eld °	f.6159.0.0	f.6159.0.1	f.6159.0.2	f.6159.0.3	f.6159.0.4	f.6159.0.5	f.6159.0.6	f.6159.1.0	f.6159.1.1	f.6159.1.2	f.6159.1.3	f.6159.1.4	f.6159.1.5	° f.
1	1000016	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
2	1000021	1	3	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	- 1
3	1000033	-7	NA	NA	NA	NA	NA	NA	-7	NA	NA	NA	NA	NA	
4	1000049	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
5	1000057	1	7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
6	1000065	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
7	1000070	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
8	1000082	1	4	5	6	7	NA	NA	NA	NA	NA	NA	NA	NA	
9	1000098	7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
10	1000103	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
11	1000111	1	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
12	1000126	-7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
13	1000134	4	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	1000142		4	6	7	NA	NA	NA							
	1000155		7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA NA	NA	
	1000155		NA	NA.	NA	NA NA	NA	NA	NA.	NA	NA NA	NA	NA NA	NA	
					NA	NA NA	NA NA	NA NA	NA NA	NA NA	NA NA	NA NA	NA NA	NA NA	
	1000178		4	6											
	1000189		NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
	1000190		7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
20	1000205	7	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	

#### A Raw UKB Subtable 6159 and Related Fields

10 M 7	Fiter											Q	
.3571.1.0	f.3571.2.0	f.3741.0.0 °	f.3741.1.0 °	f.3741.2.0 °	f.3773.0.0 °	f.3773.1.0 °	f.3773.2.0 °	f.3799.0.0 °	f.3799.1.0 °	f.3799.2.0 ÷	f.4067.0.0 °	f.4067.1.0 °	f.4067.2.0
LA .	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	1	NA	NA	NA	NA	NA
(A	0	NA	NA										
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	1	NA	NA	0	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	1	NA	NA	1	NA	NA	1	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	1	NA	NA						
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	0	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	1	NA	NA						
LA .	NA	NA	NA	NA	1	NA	NA						
(A	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	NA	NA	NA	0	NA	NA	NA	NA	NA
(A	NA	NA	NA	NA	1	NA	NA						
LA .	NA	1	NA	NA	1	NA	NA						
	NA	NA	NA	NA	1	NA	NA						

#### Converted Table for Pain and Duration:

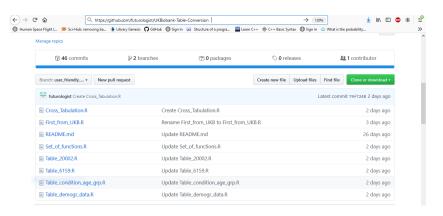
		Ÿ Filter										(Q,
ID		Prf_no_Ansr_v0	Non_Abve_v0	All_over_v0	Neck_Shldr_pn_v0	Hip_pn_v0	Back_pn_v0	Stom_Abdmn_pn_v0	Knee_pn_v0	Headch_v0	Face_pn_v0	Prf_no_Ansr_v
10	00016	0	1	0	0	0	0	0	0	0	0	NA
10	00021	0	0	0	1	0	0	0	0	1	0	NA
10	00033	0	1	0	0	0	0	0	0	0	0	0
10	00049	0	1	0	0	0	0	0	0	0	0	NA
10	00057	0	0	0	0	0	0	0	1	1	0	NA
10	00065	0	1	0	0	0	0	0	0	0	0	NA
10	00070	0	1	0	0	0	0	0	0	0	0	NA
10	00082	0	0	0	0	1	1	1	1	1	0	NA
10	00098	0	0	0	0	0	0	0	1	0	0	NA
10	00103	0	1	0	0	0	0	0	0	0	0	NA
10	00111	0	0	0	0	0	0	0	0	1	0	NA
10	00126	0	1	0	0	0	0	0	0	0	0	NA
10	00134	0	0	0	0	0	1	0	0	0	0	NA
10	00142	0	0	0	1	1	1	0	1	0	0	NA
10	00155	0	0	0	0	1	0	0	1	0	0	NA
10	00167	0	1	0	0	0	0	0	0	0	0	NA
10	00178	0	0	0	0	1	1	0	0	1	0	NA
10	00189	Rectangular Snip	0	0	0	0	0	0	1	0	0	NA
10	00190	0	0	0	0	0	0	1	1	0	0	NA
	00205	0	0	0	0	0	0	0	1	0	0	NA

#### Converted Table for Pain and Duration:

40 12 1 7	Filter Cols: « < 1-	50 >>>						Q,		
Face_pn_v2 °	All_over_3+m_v0 *	Neck_Shldr_pn_3+m_v0 **	Hip_pn_3+m_v0 *	Back_pn_3+m_v0 **	Stom_Abdmn_pn_3+m_v0	Knee_pn_3+m_v0	Headch_3+m_v0 **	Face_pn_3+m_v0	All_o	ver_
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	- 1
NA	NA	0	NA	NA	NA	NA	1	NA	NA	
0	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	1	0	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	1	1	1	1	1	NA	NA	
NA	NA	NA	NA	NA	NA	1	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	0	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	1	NA	NA	NA	NA	NA	
NA	NA	1	1	1	NA	1	NA	NA	NA	
NA	NA	NA	1	NA	NA	1	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA .	NA	NA	0	0	NA	NA	0	NA	NA	
VA	NA NA	NA	NA	NA	NA	1	NA	NA	NA	
NA	NA	NA	NA	NA	1	1	NA	NA	NA	
VA	NA	NA	NA	NA	NA	1	NA	NA	NA	
1	of 502,599 entries, 55 to									

#### R Code for Table Conversion:

**Important:** The code extracts from \*.r.tab files, columns (fields) have headers f.datafieldnum.visit.arrayindx i.e. f.6159.1.3



Converts some subtables of the original raw UKB data into analysis friendly data tables

#### Instruction:

**Step 1:** Use script **First\_from\_UKB.R** to extracts a raw subtable from the big raw UKB data file

The next scripts import and use the file of R functions: **Set of functions.R** 

Step 2: After the raw subtatble is being extracted

2.1. Field 20002 and related: Use Table\_20002.R

2.2. Field 6159 and related: Use Table\_6159.R

**2.3.** Fields of demographic data (e.g. Age, Gender, Principal Components, etc): Use **Table\_demogr\_data.R** 

Step 3: Further conversions:

**3.1.** A medical condition from field 20002 together with categorization for Age of Onset: Use **Table\_condition\_age\_grp.R** 

3.2. Cross-tabulation of two tables: Use Cross\_Tabulation.R



#### First\_from\_UKB.R

```
□ □ Source on Save □ ≫ • □
#!/usr/bin/env Rscript
library(dplvr)
library(data.table)
extract UKB subtable <- function(data base, list of codes){
  headers <- names(data base)
  pos <- c(1)
  for(code in list_of_codes){
    pos <- c(pos, grep(code, headers))
  subt <- data_base[, ..pos]
  subt <- subt[order(subt[,'f.eid']), ]
  subt
# For a set of fields that need to be extracted from the central UKB data table
# list a vector of strings, each string in the format "f.[Field_number].", for each field.
# Skip the first column, id column "f.eid", it is authomatically included
list_of_codes <- c("f.6159.", "f.2956.", "f.3404.", "f.3414.", "f.3571.", "f.3741.", "f.3773.", "f.3799.", "f.4067.")
#list_of_codes <- c("f.135.", "f.20002.", "f.20009.")
#list_of_codes <- c("f.137.", "f.20003.")
filepath_in <- "/mnt/nfs/backup/data/uk_biobank/ukb22741.r.tab" #string
filepath out <- "/home/ndimit2/Asthma and Pain/Output data ph1/ukb6159.txt"
data base <- fread(filepath in)
subtable <- extract_UKB_subtable(data_base, list_of_codes)</pre>
write.table(subtable, filepath_out, append = FALSE, sep = "\t", quote = FALSE, col.names=TRUE, row.names=FALSE)
#To run this from the UNIX command line, type and execute: chmod +x table extraction.r
# ./table_extraction.r world
```

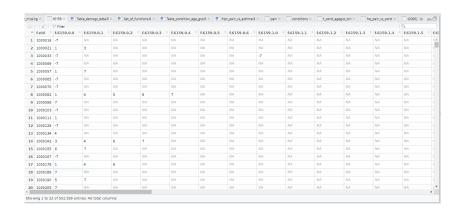
#### The Result is a Raw UKB Subtable:

Here: Related Data-Fields 135 (number of self-reported conditions) 20002 (self-reported conditions) and 20009 (age of onset)

		Filter Cols:	« < 1 - 50	> >>									(Q,	
*	f.eid :	f.135.0.0 °	f.135.1.0 °	f.135.2.0 °	f.20002.0.0 <sup>‡</sup>	f.20002.0.1 °	f.20002.0.2 °	f.20002.0.3 °	f.20002.0.4 °	f.20002.0.5 °	f.20002.0.6 °	f.20002.0.7 <sup>‡</sup>	f.20002.0.8 <sup>0</sup>	f.20002.
1	1000016	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	1000021	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
3	1000033	1	5	0	1537	NA	NA	NA						
4	1000049	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
5	1000057	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
6	1000065	1	NA	NA	1462	NA	NA	NA						
7	1000070	3	NA	NA	1065	1473	1465	NA	NA	NA	NA	NA	NA	NA
8	1000082	2	NA	NA	1278	1309	NA	NA	NA	NA	NA	NA	NA	NA
9	1000098	4	NA	NA	1465	1387	1529	1666	NA	NA	NA	NA	NA	NA
LO	1000103	1	NA	NA	1075	NA	NA	NA						
11	1000111	1	NA	NA	1426	NA	NA	NA						
12	1000126	4	NA	NA	1065	1111	1138	1286	NA	NA	NA	NA	NA	NA
L3	1000134	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
14	1000142	2	NA	NA	1412	1311	NA	NA	NA	NA	NA	NA	NA	NA
LS	1000155	6	NA	NA	1075	1074	1065	1473	1465	1078	NA	NA	NA	NA
16	1000167	0	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
17	1000178	1	NA	NA	1111	NA	NA	NA						
18	1000189	1	NA	NA	1465	NA	NA	NA						
19	1000190	1	NA	NA	1135	NA	NA	NA						
20	1000205	1	NA	NA	1473	NA	NA	NA .						

#### The Result is a Raw UKB Subtable:

Here: Data-Field 6159 (Pain) and related fields of duration of pain



#### Table 20002.R

```
source("C:\\MY_FOLDERS\\Asthma_and_Pain\\R_code\\Table_creation\\Set_of_functions.R")
filepath20002_in <- "C:\\MY_FOLDERS\\Asthma_and_Pain\\Output_data_ph1\\ukb20002.txt"
list of conditions <- c(1111, 1387, 1452)
list of labels <- c('Asthma', 'Havf Rhin', 'Eczema')
filepath20002 out <- "C:\\MY FOLDERS\\Asthma and Pain\\Output data ph2\\asth rhin ecz.txt"
n visits <- 3
1_array <- 29 # there are 29 fields for conditions per visit
start_pos <- 5 # the columns with codes for conditions start with column 5 and end with columns 5+3*29-1 = 91
t20002 <- fread(filepath20002 in) #502599
t20002 bin <- build cond and age diag table(t20002.
                              list of conditions.
                              list_of_labels,
                              n visits.
                              1_array,
                              start_pos)
names(t20002_bin)[1] <- 'ID'
t20002_bin_reord <- group_by_visit(t20002_bin, list_of_conditions, n_visits)
t20002_cond_age <- group_cond_age(t20002_bin, list_of_conditions, n_visits)
write.table(t20002 bin.
        filepath20002 out.
```

# Converted Table for conditions Asthma, Hay-Fever, Eczema including Age of Onset:

		7 filter										(Q,		
*	ID ÷	Asthma_v0	Asthma_v1	Asthma_v2	Hayf_Rhin_v0	Hayf_Rhin_v1 **	Hayf_Rhin_v2	Eczema_v0 ÷	Eczema_v1 °	Eczema_v2 <sup>0</sup>	age_Asthma_v0 **	age_Asthma_v1	age_	Ast
1	1000016	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
2	1000021	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
3	1000033	0	0	0	0	1	0	0	0	0	NA	NA	NA	
4	1000049	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
5	1000057	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
6	1000065	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
7	1000070	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
8	1000082	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
9	1000098	0	NA	NA	1	NA	NA	0	NA	NA	NA	NA	NA	
10	1000103	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
11	1000111	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
2	1000126	1	NA	NA	0	NA	NA	0	NA	NA	53.5000	NA	NA	
13	1000134	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
4	1000142	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
15	1000155	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
16	1000167	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
17	1000178	1	NA	NA	0	NA	NA	0	NA	NA	-1.0000	NA	NA	
8	1000189	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
9	1000190	0	NA	NA	0	NA	NA	0	NA	NA	NA	NA	NA	
0	1000205	0	NA	NA	0	NA		0	NA	NA	NA	NA	NA	,

# Converted Table for conditions Asthma, Hay-Fever, Eczema including Age of Onset:

>   🔊   🤊 filte	r								(Q,
Eczema_v2	age_Asthma_v0	age_Asthma_v1 **	age_Asthma_v2	age_Hayf_Rhin_v0	age_Hayf_Rhin_v1 **	age_Hayf_Rhin_v2	age_Eczema_v0 °	age_Eczema_v1 **	age_Eczema_v2
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
0	NA	NA	NA	NA	44.5785	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	24.50000	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	53.5000	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	-1.0000	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA

#### **Table 6159.R**

Source("C:\\MY FOLDERS\\Asthma and Pain\\R code\\Table creation\\Set of functions.R") filepath6159\_in <- "C:\\MY\_FOLDERS\\Asthma\_and\_Pain\\Output\_data\_ph1\\ukb6159.txt" # you can change the lables that follow, but preservet their order: list\_of\_labels <- c('Prf\_no\_Ansr', 'Non\_Abve', 'All\_over', 'Non\_Abve', 'Back\_pn', 'Stom\_Abdmn\_pn', 'Knee\_pn', 'Headch', 'Face\_pn') # you can change the lables that follow, but preservet their order: labels <- c('All\_over\_3+m', 'Neck\_Shldr\_pn\_3+m', 'Hip\_pn\_3+m', 'Back\_pn\_3+m', 'Stom\_Abdmn\_pn\_3+m', 'Knee\_pn\_3+m', 'Headch\_3+m', 'Face\_pn\_3+m') filepath6159 out <- "C:\\MY FOLDERS\\Asthma and Pain\\Output data ph2\\UKB Pain Duration.txt" n\_visits <- 3 # The number of visits can change to 4 when the fourth visit becomes available and is inculded in the UKB table list\_of\_sites <- c(-3, -7, 8, 3, 6, 4, 5, 7, 1, 2) # Do not change. 1\_array <- 7 # there are 7 fields for pain states per visit start pos <- 2 # the columns with codes for pain sites start with column 2 and end with column 2+3\*7-1 = 22 #The order of the conditions and the lables is based on the order of the fields from the file First from UKB.R #They were: #list\_of\_codes <- c("f.6159.", "f.2956.", "f.3404.", "f.3414.", "f.3571.", "f.3741.", "f.3773.", "f.3799.", "f.4067.") #fields <- c("f.3799.", "f.4067.", "f.3404.", "f.3571.", "f.3741.", "f.3414.", "f.3773.", "f.2956.") fields <- c("f.2956.", "f.3404.", "f.3414.", "f.3571.", "f.3741.", "f.3773.", "f.3799.", "f.4067.")  $arrays_length <- c(1, 1, 1, 1, 1, 1, 1, 1)$ instances <- 3 \* arrays\_length 

#### Converted Table for Pain and Duration:

		▽ Filter										Q
	ID 0	Prf_no_Ansr_v0	Non_Abve_v0	All_over_v0	Neck_Shldr_pn_v0	Hip_pn_v0	Back_pn_v0 °	Stom_Abdmn_pn_v0	Knee_pn_v0	Headch_v0 °	Face_pn_v0	Prf_no_Ansr_v
ı	1000016	0	1	0	0	0	0	0	0	0	0	NA
2	1000021	0	0	0	1	0	0	0	0	1	0	NA
3	1000033	0	1	0	0	0	0	0	0	0	0	0
4	1000049	0	1	0	0	0	0	0	0	0	0	NA
5	1000057	0	0	0	0	0	0	0	1	1	0	NA
6	1000065	0	1	0	0	0	0	0	0	0	0	NA
7	1000070	0	1	0	0	0	0	0	0	0	0	NA
8	1000082	0	0	0	0	1	1	1	1	1	0	NA
9	1000098	0	0	0	0	0	0	0	1	0	0	NA
0	1000103	0	1	0	0	0	0	0	0	0	0	NA
1	1000111	0	0	0	0	0	0	0	0	1	0	NA
2	1000126	0	1	0	0	0	0	0	0	0	0	NA
3	1000134	0	0	0	0	0	1	0	0	0	0	NA
4	1000142	0	0	0	1	1	1	0	1	0	0	NA
5	1000155	0	0	0	0	1	0	0	1	0	0	NA
6	1000167	0	1	0	0	0	0	0	0	0	0	NA
7	1000178	0	0	0	0	1	1	0	0	1	0	NA
8	1000189	Rectangular Snip	0	0	0	0	0	0	1	0	0	NA
9	1000190	0	0	0	0	0	0	1	1	0	0	NA
0	1000205	0	0	0	0	0	0	0	1	0	0	NA

#### Converted Table for Pain and Duration:

00 D S	Filter Cols: « < 1-	50 >>>						Q,		
Face_pn_v2	All_over_3+m_v0	Neck_Shldr_pn_3+m_v0	Hip_pn_3+m_v0	Back_pn_3+m_v0	Stom_Abdmn_pn_3+m_v0	Knee_pn_3+m_v0	Headch_3+m_v0	Face_pn_3+m_v0	° All_o	ver.
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	0	NA	NA	NA	NA	1	NA	NA	
0	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	1	0	NA	NA	
NA	NA	NA	NA	NA	NA	MA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	1	1	1	1	1	NA	NA	
VA	NA	NA	NA	NA	NA	1	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	NA	NA	NA	0	NA	NA	
NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	NA	1	NA	NA	NA	NA	NA	
NA	NA	1	1	1	NA	1	NA	NA	NA	
NA	NA	NA	1	NA	NA	1	NA	NA	NA	
VA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
NA	NA	NA	0	0	NA	NA	0	NA	NA	
VA	NA NA	NA	NA	NA	NA	1	NA	NA	NA	
VA	NA	NA	NA	NA	1	1	NA	NA	NA	
IA .	NA	NA	NA	NA	NA	1	NA	NA	NA	
	of 502,599 entries, 55 to				no.	1				

#### Table\_demogr\_data.R

```
source("C:\\MY_FOLDERS\\Asthma_and_Pain\\R_code\\Table_creation\\Set_of_functions.R")
#If you would like to extract additional data, such as demographic and pricniple components from UKB, use this script
#The tables are extracted "as they are" columns are selected as desired
#when selecting a subset of the fields, make sure the order of the fileds is in ascending order
#(as it is in the raw UKB table) and the array lengths, the instances and the lables correpsond to the respective fields
# also make sure, that the fields you are choosing are present in the raw UKB data table at pathfile in
pathfile in <- "C:\\MY FOLDERS\\Asthma and Pain\\Output data ph1\\ukb demogr geno info.txt"
fields <- c('f.31.', 'f.21000.', 'f.21003.', 'f.22001.', 'f.22006.', 'f.22009.'. 'f.22010.'. 'f.22018.')
arrays_length <- c(1, 1, 1, 1, 1, 40, 1, 1)
instances <- c(1, 3, 3, 1, 1, 1, 1, 1)
labels <- c("Sex", "Ethnic_backgr", "Age_at_Visit", "Genetic_sex",
          "Gen_ethnic_grp", "PC", "Geno_analys_exclns",
          "Relat exclns")
#fields <- c(21000, 22006, 22009)
#arrays length <- c( 1, 1, 40)
#instances <- c(3, 1, 1)
#labels <- c("Ethnic_backgr", "Gen_ethnic_grp", "PC")</pre>
filepath out <- "C:\\MY FOLDERS\\Asthma and Pain\\Output data ph2\\asth rhin ecz demogr.txt"
t_demogr_geno_info <- fread(pathfile_in) #502599
t_demogr_geno_info <- extract_subtable(t_demogr_geno_info, fields)
names(t_demogr_geno_info) <- relabel(t_demogr_geno_info, fields, array_length, instances, labels)
names(t demogr geno info)[1] <- 'ID'
asth_rhin_ecz_demogr <- left_join(t20002_bin, t_demogr_geno_info, by = "ID")
write.table(asth_rhin_ecz_demogr, Filepath_out,
          append = FALSE, sep = "\t", quote = FALSE, col,names=TRUE, row,names=FALSE)
```

### Demographic Table:

	ID ÷	Sex -	Ethnic_backgr_v0	Ethnic_backgr_v1	Ethnic_backgr_v2	Genetic_sex	Gen_ethnic_grp	PC_1	PC_2	PC_3	PC_4	PC_5 ÷	PC_6 °	PC_7
L	1000016	1	1001	NA	NA	1	1	-14.971300	6.569230	-1.3365300	0.92670900	-5.1387900	0.71295100	1.00137
2	1000021	1	1003	NA	NA	1	NA	-14.386900	4.848020	-1.4494900	0.16317500	-12.7189000	4.05945000	-6.6349
3	1000033	1	4002	6	4002	1	NA	404.239000	78.346700	-7.3963800	5.06768000	1.3545800	1.26281000	-5.1710
1	1000049	0	1001	NA	NA	0	1	-14.186200	5.049800	1.1151700	1.44953000	3.7704100	-1.02480000	-1.1049
5	1000057	1	1001	NA	NA	1	1	-11.732400	2.347860	-2.1769300	-0.77984700	-1.5601300	0.30691700	0.79568
5	1000065	1	1001	NA	NA	1	1	-11.669800	3.402110	0.1570150	-0.68362400	-9.2771500	-0.54041600	1.30481
,	1000070	1	1001	NA	NA	1	1	-13.510500	6.019790	-2.2976800	3.54059000	0.3880490	-0.07259120	-1.7648
	1000082	0	1001	NA	NA	0	1	-12.255400	3.367310	-2.0331000	-3.20088000	-7.8891200	-1.47467000	0.65193
	1000098	0	1001	NA	NA	0	1	-12.380700	6.652540	-0.3084850	3.61791000	0.3283630	2.03677000	0.86099
	1000103	1	1001	NA	NA	1	1	-13.652900	4.977300	-2.0118900	6.04367000	10.5052000	-0.21671700	-1.0284
	1000111	1	1001	NA	NA	1	1	-11.124800	2.267640	0.3657850	0.48853700	-1.5978400	1.34270000	1.75745
2	1000126	1	1001	NA	NA	1	1	-13.801400	1.992730	-0.3710420	5.02652000	5.0188100	-3.45319000	-0.8898
3	1000134	1	1001	NA	NA	1	1	-12.784500	2.322710	-1.4030400	3.80499000	16.1347000	-1.82734000	1.18045
	1000142	0	1001	NA	NA	0	1	-12.883700	5.586510	-0.1269750	-2.31585000	-5.9124100	-0.50693400	-1.5391
5	1000155	1	1001	NA	NA	1	1	-9.397750	1.280260	-2.3414600	-1.88726000	1.7767700	-0.88299100	3.77995
5	1000167	1	1001	NA	NA	1	1	-12.984000	2.344330	-3.4956900	2.87668000	-6.1619000	-0.83405200	0.29266
	1000178	1	1001	NA	NA	0	1	-12.691700	3.537740	-5.2217800	3.09525000	2.5255200	-1.69996000	0.50972
	1000189	1 Rectar	1001	NA	NA	1	1	-9.596010	1.870230	-3.2655500	0.33014600	-4.2363800	-1.20747000	0.31209
	1000190	0	1001	NA	NA	0	1	-15.294400	3.606250	-3.3196700	7.13003000	15.6512000	-0.13457200	2.68751
	1000205	1	1001	NA	NA	1	NA	21.153400	-11.274600	28.8372000	-81.36310000	15.1426000	-5.69029000	-25.020

#### Table\_condition\_age\_grp.R

source("C:\\MY FOLDERS\\Asthma and Pain\\R code\\Table creation\\Set of functions.R") # THIS SCRIPT USES THE REUSLTS FROM THE SCRIPT 'Table\_20002.R', SO YOU MAY HAVE TO RUN 'Table\_20002.R' FIRST. # FOR THIS SCRIPT TO WORK PROPERLY, YOU HAVE TO MAKE SURE THE HEALTH CONDITION LABEL (E.G. "Asthma") # PROVIDED HERE MATCHES THE CORRESPONDING LABEL IN THE # TABLE(S) EXTRACTED WITH THE SCRIPT 'Table 20002.R'. n visits <- 3 # The number of visits my go up to 4 when updates of the database is available 1\_array <- 29 # there are 29 fields for conditions per visit start\_pos <- 5 # the columns with codes for conditions start with column 5 and end with columns 5+3\*29-1 = 91 # Choose one of the tables, generated by the script 'Table 20002.R' : t\_cond <- t20002\_bin # Refer to the headers of either table t20002 bin, t20002 bin reord or t20002 cond age. # or alternatively, the script 'Table\_20002.R' and the choose the label form the provided there condition <- "Asthma" age\_groups  $\leftarrow$  list(c(0.18), c(18.40), c(40, 120)) # Provide your own age group intervals age\_group\_lbls <- c('Age\_6', 'Age\_4', 'Age\_5') # Provide your own labels for the age groups above filepath\_out <- "C:\\MY\_FOLDERS\\Asthma\_and\_Pain\\Output\_data\_ph2\\asthma\_age\_groups.txt" t\_cond\_agegrp\_bin <- build\_cond\_agegrp\_bin(t\_cond, condition, age\_groups, age\_group\_lbls, n\_visits, keep\_NA = TRUE) write.table(t cond ageorp bin. filepath\_out. append = FALSE, sep = "\t", quote = FALSE, col.names=TRUE, row.names=FALSE)

#### Condition with Age of Onset Groups:

ID S	Asthma_v0	Asthma_Age_6_v0	Asthma_Age_4_v0	Asthma_Age_5_v0	Asthma_v1	Asthma_Age_6_v1	Asthma_Age_4_v1	Asthma_Age_5_v1	Asthma_v2	Asthma_Age_
1000016	0	0	0	0	NA	NA	NA	NA	NA	NA
1000021	0	0	0	0	NA	NA	NA	NA	NA	NA
1000033	0	0	0	0	0	0	0	0	0	0
1000049	0	0	0	0	NA	NA	NA	NA	NA	NA
1000057	0	0	0	0	NA	NA	NA	NA	NA	NA
1000065	0	0	0	0	NA	NA	NA	NA	NA	NA
1000070	0	0	0	0	NA	NA	NA	NA	NA	NA
1000082	0	0	0	0	NA	NA	NA	NA	NA	NA
1000098	0	0	0	0	NA	NA	NA	NA	NA	NA
1000103	0	0	0	0	NA	NA	NA	NA	NA	NA
1000111	0	0	0	0	NA	NA	NA	NA	NA	NA
1000126	1	NA	NA	1	NA	NA	NA	NA	NA	NA
1000134	0	0	0	0	NA	NA	NA	NA	NA	NA
1000142	0	0	0	0	NA	NA	NA	NA	NA	NA
1000155	0	0	0	0	NA	NA	NA	NA	NA	NA.
1000167	0	0	0	0	NA	NA	NA	NA	NA	NA
1000178	1	NA	NA	NA	NA	NA	NA	NA	NA	NA.
1000189	0	0	0	0	NA	NA	NA	NA	NA	NA
1000190	0	0	0	0	NA	NA	NA	NA	NA	NA
1000205	0	0	0	0	NA	NA	NA	NA	NA	NA

#### Cross Tabulation.R

```
library(dplyr)
library(data.table)
# THIS SCRIPT USES THE REUSLTS FROM THE SCRIPTS 'Table_condition_age_grp.R' and 'Table_6159.R',
# OR ALTERNATIVELY, FROM YOUR OWN SCRIPTS
# SO YOU MAY HAVE TO RUN THESE TWO SCRIPTS EIRST.
create_frequency_table <- function(pain, conditions){</pre>
  id <- intersect(select(pain, 'ID'), select(conditions, 'ID'))</pre>
  pain_loc <- left_join(id, pain, by='ID')
  conditions_loc <- left_join(id, conditions, by='ID')
  pain_loc \leftarrow pain_loc[.(2:length(pain[1.]))]
  conditions_loc <- conditions_loc[,(2:length(conditions_loc[1,]))]
  pain_loc[is.na(pain_loc)] <- 0
  conditions_loc[is.na( conditions_loc)] <- 0
  D <- data.matrix(pain_loc)</pre>
  P <- data.matrix(conditions_loc)</pre>
  R <- t(D) %*% P
  R <- as.data.table(R, keep.rownames = TRUE)</pre>
  return(R)
################################# PROVIDE OUPUT LOCATION #########
filepath_out <- "C:\\MY_FOLDERS\\Asthma_and_Pain\\Output_data_ph2\\cross_table_pain_vs_cond.txt"
conditions <- t_cond_agegrp_bin
pain <- t_pain
cross_pain_vs_cond <- create_frequency_table(pain, conditions)</pre>
```

#### Cross Table Pain Sites vs a Medical Condition:

	rn ÷	Missing_20002_v0	Controls_v0	Asthma_v0	Asthma_Age_6_v0	Asthma_Age_4_v0	Asthma_Age_5_v0	Missing_20002_v1	Controls_v1	Asthma_vl	Asthma
1	Missing_6159_v0	391	1634	166	25	42	71	2169	20	2	0
2	Non_Abve_v0	143	178258	18735	6163	4748	6459	188231	8040	865	287
3	All_over_v0	21	7208	1616	283	446	746	8620	187	38	10
4	Neck_Shidr_pn_v0	131	100353	16535	4178	4460	6533	112687	3721	611	152
5	Hip_pn_v0	57	47748	8498	1835	2102	3799	54279	1723	301	67
6	Back_pn_v0	143	111915	18052	4564	4834	7157	125371	4108	631	150
7	Stom_Abdmn_pn_v0	57	36881	7057	1772	2162	2538	42410	1308	277	64
8	Knee_pn_v0	109	93061	15025	3690	3826	6218	104191	3444	560	136
9	Headch_v0	125	87955	14908	3927	4691	5012	99157	3267	564	143
LO	Face_pn_v0	15	7807	1521	331	452	592	8977	310	56	11
11	Missing_6159_v1	856	429103	56685	16009	15191	21025	482262	3650	732	192
12	Non_Abve_v1	1	8921	965	315	247	332	2	8878	1007	326
13	All_over_v1	0	184	34	6	7	20	0	181	37	8
4	Neck_Shldr_pn_v1	2	3229	504	124	147	196	1	3192	542	130
L5	Hip_pn_v1	2	1815	294	72	82	120	0	1800	311	76
16	Back_pn_v1	3	3571	543	147	154	205	0	3544	573	146
17	Stom_Abdmn_pn_v1	0	1006	177	39	62	66	0	997	186	42
18	Knee_pn_v1	2	3431	513	131	141	205	0	3423	523	130
19	Headch_v1	1	2196	350	81	128	111	0	2174	373	95
	Face_pn_v1	0	214	43	9	11	17	0	211	46	11